

INFORME TÉCNICO

Incendios forestales en Chile y estrés hídrico

Cruce de 60.530 eventos de CONAF (2010-2019) con el reanálisis climático ERA5

MergeGeo

Samsung Innovation Campus — Big Data 2026

github.com/Mtys24/MergeGeo

Equipo

Jairo Arias Valenzuela · Fabian Valdés · Matías Manríquez · Javiera González Mardones · José Salgado Escalona

Resumen ejecutivo

Este informe documenta MergeGeo, un pipeline de análisis masivo de datos que integra 60.530 registros de incendios forestales de CONAF (2010-2019) con el reanálisis climático ERA5 (2000-2025) y con la serie nacional mensual de ocurrencia de CONAF (1985-2024), con el fin de evaluar si el estrés hídrico —temperatura anómalamente alta combinada con precipitación anómalamente baja— se asocia con incendios de mayor severidad en Chile.

El trabajo construyó un índice de estrés hídrico basado en z-scores de anomalías mensuales, agregó los eventos a nivel de comuna y año mediante Apache Spark, produjo tres mapas geoespaciales interactivos y entrenó dos modelos de aprendizaje automático: un clasificador de riesgo comunal y un regresor de tendencia nacional, ambos con XGBoost. Todos los resultados se consolidaron en un dashboard HTML autocontenido.

El hallazgo principal es matizado y se sostiene en dos niveles de análisis distintos. A nivel de evento individual la hipótesis se confirma con claridad: los incendios del 1 % superior de superficie quemada ocurrieron con una anomalía térmica media de +0,49 desviaciones estándar, casi el triple que el resto de los eventos (+0,18), y con una cuarta parte de la precipitación (0,049 mm frente a 0,209 mm). A nivel de comuna-año, en cambio, un clasificador alimentado exclusivamente con variables climáticas alcanza apenas 36,2 % de accuracy sobre cuatro clases —mejor que el 25 % del azar, pero lejos de ser predictivo—, y la región resulta tan importante como el clima entre las variables del modelo.

La conclusión que se desprende es que el clima anómalo define el techo de lo que puede quemarse, pero no determina cuánto se quema: la disponibilidad de combustible, la vegetación y sobre todo la actividad humana —el 90,7 % de los eventos tiene una causa humana identificada— explican la diferencia entre un año seco sin consecuencias y un año seco catastrófico.

1. Introducción

1.1 Contexto

Chile registra entre 4.000 y 8.000 incendios forestales por temporada, concentrados casi íntegramente en el verano austral. En el período analizado, el 79,9 % de los eventos ocurrió entre diciembre y marzo. El daño, sin embargo, no se distribuye de forma pareja: la superficie quemada está extraordinariamente concentrada, tanto en el tiempo como en unos pocos eventos.

Existen registros públicos de alta calidad para ambos fenómenos —el fuego y el clima— pero se encuentran en formatos y estructuras incompatibles. El registro de incendios de CONAF es una lista de eventos puntuales con coordenadas y fecha; el reanálisis ERA5 es una grilla continua de variables meteorológicas. Ninguno de los dos, por sí solo, permite responder si el clima anómalo agrava los incendios.

1.2 Problema

El problema abordado es de integración de datos antes que de modelamiento: se requiere unir un conjunto de eventos georreferenciados con una grilla climática diaria, resolviendo la correspondencia espacial (qué celda contiene cada evento) y temporal (qué día y qué mes corresponde), a una escala que hace inviable el procesamiento en una planilla de cálculo.

1.3 Alcance

El estudio cubre Chile continental entre 2010 y 2019 a nivel de evento y comuna, y el período 1985-2024 a nivel de serie nacional mensual. Quedan fuera del alcance las variables no climáticas del riesgo —tipo de vegetación, densidad de población, interfaz urbano-rural— así como cualquier pronóstico operativo de incendios.

2. Objetivos

2.1 Objetivo general

Construir evidencia cuantitativa sobre la relación entre estrés hídrico y severidad de incendios forestales en Chile, integrando fuentes de datos oficiales de incendios y clima a nivel de comuna.

2.2 Objetivos específicos

1. Integrar los registros de incendios de CONAF con el clima diario real de ERA5 y con la serie histórica nacional de ocurrencia.
2. Definir un índice de estrés hídrico comparable entre comunas de climas base distintos.
3. Agregar los eventos a nivel de comuna y año mediante procesamiento distribuido, calculando indicadores de severidad y un ranking anual.
4. Entrenar un modelo capaz de clasificar el riesgo de cada comuna-año utilizando únicamente variables climáticas.
5. Producir visualizaciones geoespaciales interactivas de severidad histórica, estrés hídrico y eventos de importancia.
6. Consolidar los resultados en un dashboard autocontenido dirigido a una audiencia no técnica.

3. Hipótesis

El estrés hídrico a nivel comunal —temperatura anómalamente alta combinada con precipitación anómalamente baja respecto de la climatología histórica del propio lugar— se asocia con incendios forestales de mayor severidad.

De la hipótesis se derivan tres consecuencias observables que orientaron el diseño del análisis:

- Las comunas que atraviesan meses más cálidos y secos que su propia normal histórica deberían presentar mayor superficie quemada anual.
- Deberían presentar además una mayor frecuencia de eventos catastróficos.

- La relación debería sostenerse al comparar comunas entre sí a lo largo de todo el territorio, lo que exige una medida de anomalía normalizada y no valores absolutos de temperatura o lluvia.

Para hacerla medible se construyó un índice de estrés hídrico definido como la diferencia entre el z-score de la anomalía de temperatura y el z-score de la anomalía de precipitación. La resta invierte el signo de la precipitación, de modo que la escasez de lluvia incrementa el índice:

$$\text{estrés_hídrico} = z(\text{anomalía } t2m) - z(\text{anomalía } tp)$$

La estrategia de contraste consistió en entrenar un clasificador de riesgo comunal alimentado exclusivamente con variables climáticas, sin ninguna variable derivada del historial de incendios. Esta restricción evita la fuga de información (data leakage) que se produciría al usar incendios pasados para predecir incendios futuros, y convierte el desempeño del modelo en una prueba directa de cuánta información sobre la severidad contiene el clima por sí solo.

4. Datos

4.1 Fuentes

Tabla 1. Fuentes de datos integradas.

Fuente	Contenido	Volumen	Período	Origen
CONAF — eventos	Incendios individuales: fecha, coordenadas, causa y superficie quemada por tipo de vegetación	60.530 eventos	2010-2019	datospararesiliencia.cl (API, 18 temporadas)
ERA5	Temperatura a 2 m (t2m) y precipitación total (tp) diarias en grilla regular de 0,25°	~3.600 celdas	2000-2025	Copernicus Climate Data Store (NetCDF)
CONAF — Archivo 6	Serie histórica nacional mensual de ocurrencia de incendios	480 meses	1985-2024	CONAF (planilla oficial)

4.2 Limpieza y control de calidad

Los notebooks 01 y 02 combinaron 18 temporadas descargadas desde la API de CONAF, normalizaron los formatos de fecha y las coordenadas, y filtraron los registros a Chile continental. El proceso resultó en 60.530 eventos válidos. En la etapa de agregación con Spark no se descartaron filas adicionales por ausencia de comuna, región o año, lo que confirma la integridad del conjunto depurado.

La distribución de la superficie quemada por evento es fuertemente asimétrica: la mediana es de 0,35 hectáreas y la media de 19,13 hectáreas. Esta asimetría motivó el uso de la transformación logarítmica $\log(1 + \text{superficie})$ en los análisis exploratorios y la definición de categorías de severidad por cuantiles en lugar de umbrales absolutos.

4.3 Variables del conjunto integrado

Tabla 2. Variables climáticas incorporadas a cada evento (notebook 03).

Variable	Descripción	Unidad
t2m_c	Temperatura media del aire a 2 m del día del evento, en la celda que lo contiene	°C
tp_mm	Precipitación total acumulada del día del evento	mm
t2m_anomaly_mensual	Desviación de la temperatura del mes respecto de la climatología de la celda	°C
tp_anomaly_mensual	Desviación de la precipitación del mes respecto de la climatología de la celda	mm
log_superficie_ha	Transformación $\log(1 + \text{superficie quemada})$ del evento	—

5. Metodología

5.1 Arquitectura del pipeline

El proyecto se estructuró en nueve notebooks secuenciales, donde cada uno consume la salida del anterior. Tras la preparación de los datos (01-02) y el cruce con ERA5 (03), el flujo se bifurca en una rama comunal (04, que alimenta los mapas 06-07 y el modelo 08) y una rama nacional (05). El notebook 09 consolida ambas ramas en el dashboard final. El detalle completo se encuentra en el Anexo A.

5.2 Cruce espacio-temporal

Cada evento de incendio se asignó a la celda de 0,25° de ERA5 que contiene sus coordenadas, y a esa celda se le extrajeron la temperatura y la precipitación del día del evento. Adicionalmente se calculó, para el mes y la celda correspondientes, la anomalía respecto de la climatología del período 2000-2025. El resultado es un conjunto de 60.530 filas y 34 columnas que combina, por primera vez en este proyecto, la descripción del incendio con la del clima que lo rodeó.

ERA5 — Chile · 01-07-2000




Figura 1. Reanálisis ERA5 sobre Chile para un día de la serie: precipitación total acumulada (izquierda) y temperatura media diaria (derecha). Salida del notebook de extracción ERA5.

5.3 Construcción del índice de estrés hídrico

El uso de valores absolutos de temperatura y precipitación impide comparar comunas con climas base distintos: 30 °C es un valor normal en el norte y un récord en el sur. Por ello cada variable se transformó en anomalía respecto de la climatología del propio lugar y luego se estandarizó a z-score. El índice resultante es adimensional y comparable a lo largo de todo el territorio.




Figura 2. Series diarias y mensuales de precipitación y temperatura media espacial de Chile, y sus anomalías respecto de la climatología 2000-2025.

5.4 Agregación con Apache Spark

El notebook 04 ejecuta Spark 4.0.4 en modo local[*] sobre los 60.530 eventos. Cada evento se clasifica primero en una escala de severidad, y luego se agrega por comuna y año, produciendo 2.617 combinaciones comuna-año. Para cada una se calculan el número de incendios, la superficie total, media y máxima, el número de eventos catastróficos, los promedios climáticos, el índice de estrés hídrico y un ranking anual de severidad. La salida se guarda en formato Parquet particionado por año y en CSV consolidado.

5.5 Modelo de riesgo comunal

La variable objetivo es la categoría de riesgo de cada comuna-año, definida por los cuartiles de superficie quemada anual. Tres decisiones metodológicas sostienen la validez del ejercicio:

- Los umbrales de las categorías se calcularon exclusivamente sobre el conjunto de entrenamiento ($Q1 = 7,00$ ha; $Q2 = 34,13$ ha; $Q3 = 152,66$ ha), de modo que el conjunto de prueba no influye en la definición de las clases.
- La partición es temporal y no aleatoria: se entrena con los años 2010 a 2017 (2.039 filas) y se evalúa sobre 2018 y 2019 (578 filas). El modelo predice años futuros, no filas sueltas intercaladas entre los datos de entrenamiento.

- Las 24 variables de entrada son exclusivamente climáticas y de contexto regional: promedios de temperatura y precipitación, sus anomalías en z-score, el índice de estrés hídrico y la región codificada. No se incluye ninguna variable derivada del historial de incendios.

El algoritmo empleado es XGBClassifier con 300 árboles y tasa de aprendizaje 0,05. En entrenamiento las cuatro clases quedan prácticamente balanceadas, con alrededor de 510 casos cada una.

5.6 Modelo de tendencia nacional

En paralelo, el notebook 05 cruza la serie mensual de ocurrencia nacional 1985-2024 con promedios nacionales de ERA5. De los 480 meses de la serie, 186 son anteriores a la cobertura de ERA5, por lo que el cruce efectivo con clima real abarca 294 meses (2000-2024). Se entrenó un regresor XGBoost con salvaguardas anti-extrapolación, dado que los modelos de árboles no extrapolan fuera del rango observado y forzarlos produce proyecciones sin sustento.

5.7 Entorno de ejecución

Todo el pipeline se ejecuta en Google Colab con almacenamiento en Google Drive. El stack comprende Python 3, PySpark, XGBoost, Pandas, NumPy y Scikit-learn para el procesamiento y modelamiento; xarray y NetCDF4 para la lectura de ERA5; Folium, branca y GeoJSON para la cartografía; y Plotly y Matplotlib para la visualización. Los formatos de intercambio entre notebooks son Parquet y CSV.

6. Resultados

6.1 Caracterización de los eventos

Entre 2010 y 2019 se registraron 60.530 incendios que consumieron 1.157.990 hectáreas. La distribución anual muestra una concentración extraordinaria: la temporada 2017 acumuló 512.926 hectáreas, es decir el 44,3 % de toda la superficie quemada de la década, pese a no ser el año con más eventos.

Tabla 3. Eventos y superficie quemada por año.

Año	N° de eventos	Superficie quemada (ha)
2010	4.160	51.809
2011	5.534	76.714
2012	4.292	35.269
2013	6.551	36.485
2014	6.109	87.342
2015	7.319	128.039
2016	7.452	101.605
2017	4.864	512.926
2018	6.198	35.299
2019	8.051	92.502

Total	60.530	1.157.990
-------	--------	-----------

La concentración también se verifica a nivel de evento: el 1 % de los incendios más grandes (605 eventos) explica el 82,1 % de la superficie quemada total, y el 5 % superior explica el 93,5 %. Cualquier análisis de severidad es, en la práctica, un análisis de ese pequeño subconjunto de eventos extremos.

Respecto de las causas, el 90,7 % de los eventos corresponde a categorías de origen humano directo. Los incendios intencionales son la causa más frecuente (21.966 eventos) y también la de mayor superficie asociada (339.300 ha), seguidos por el tránsito de personas, vehículos o aeronaves (19.823 eventos).

Tabla 4. Principales causas por frecuencia y por superficie quemada.

Causa	N° de eventos	Superficie (ha)
Incendios intencionales	21.966	339.300
Tránsito de personas, vehículos o aeronaves	19.823	211.525
Causa desconocida	3.144	235.997
Actividades recreativas	3.031	40.439
Faenas forestales	2.816	—
Faenas agrícolas y pecuarias	2.735	45.461
Quema de desechos	2.721	26.928
Accidentes eléctricos	1.808	151.666

La distribución territorial concentra el daño en la zona centro-sur. El Maule encabeza la superficie quemada con 339.301 hectáreas en 6.699 eventos, mientras que Biobío registra el mayor número de eventos del país —25.123— con 258.504 hectáreas. La diferencia entre ambas regiones ilustra que frecuencia y severidad no son lo mismo.

6.2 Clima de los eventos: contraste entre catastróficos y el resto

El contraste directo entre los eventos del 1 % superior de superficie quemada y el resto constituye la evidencia más nítida a favor de la hipótesis. Los eventos catastróficos ocurrieron en condiciones sistemáticamente más cálidas, más secas y —lo que es más significativo— más anómalas respecto de la normal histórica del lugar.

Tabla 5. Condiciones climáticas medias: eventos catastróficos (1 % superior) frente al resto.

Variable	Catastróficos	Resto	Diferencia
Temperatura del día (°C)	18,88	16,63	+2,25 °C
Anomalía de temperatura (z)	+0,492	+0,180	×2,7
Precipitación del día (mm)	0,049	0,209	÷4,3

La anomalía térmica media de los eventos catastróficos casi triplica la del resto. Dado que la anomalía mide la desviación respecto de la propia climatología del lugar, este resultado no puede

atribuirse a que los incendios grandes ocurran en zonas naturalmente más cálidas: ocurren en momentos anormalmente cálidos para su propia zona.




Figura 3. Superficie quemada (escala logarítmica) frente a la temperatura y la precipitación del día del evento, para los 60.530 incendios. Salida del notebook 03.

La relación observada es asimétrica. Los eventos severos se concentran entre 15 y 25 °C y prácticamente desaparecen con temperaturas bajas, pero el calor por sí solo no garantiza un incendio grande: existe una gran masa de eventos menores en ese mismo rango térmico. Con precipitación, en cambio, la severidad se desploma: casi toda la superficie quemada ocurre en días con lluvia cercana a cero. El clima, en otras palabras, opera como condición necesaria pero no suficiente.

6.3 Resultados geoespaciales

Se produjeron tres mapas interactivos en Folium, exportados como HTML independientes y embebidos posteriormente en el dashboard.




Figura 4. Severidad histórica por comuna (percentil de superficie quemada acumulada 2010-2019). El mapa interactivo permite aislar años individuales.

El mapa de severidad histórica muestra una franja continua de alta severidad entre Valparaíso y La Araucanía, coincidente con la zona de plantaciones forestales y de interfaz urbano-rural. El norte del país permanece prácticamente ausente pese a ser la zona más seca, lo que constituye la primera evidencia de que la aridez sin combustible no genera incendios. En el extremo austral reaparecen

comunas de alta severidad con muy pocos eventos, entre ellas Torres del Paine, cuyo incendio de 2011 consumió 17.606 hectáreas.



Figura 5. Índice de estrés hídrico por comuna. Al estar expresado en z-scores, el valor es comparable entre comunas de climas base distintos.

El mapa de estrés hídrico revela un desacople relevante: los valores extremos del índice no coinciden con las zonas de mayor severidad. Chaitén alcanza en 2016 un índice superior a 20, porque una sequía en el sur húmedo representa una desviación enorme respecto de su propia

normal, pero ese mismo año registra un único evento de 1,5 hectáreas. El resultado delimita con precisión el alcance de la hipótesis.




Figura 6. Densidad de eventos y puntos de importancia: eventos catastróficos (1 % superior de superficie), eventos con estrés hídrico extremo y los que cumplen ambas condiciones.

6.4 Serie nacional de largo plazo




Figura 7. Serie nacional de incendios por año 1985-2024 (arriba) y relación entre incendios mensuales y temperatura media nacional de ERA5 en el tramo cruzado 2000-2024 (abajo).

La correlación entre el número mensual de incendios a nivel nacional y la temperatura media del país es muy elevada (+0,894). Sin embargo, las correlaciones con las anomalías son prácticamente nulas (+0,058 para temperatura y $-0,082$ para precipitación), lo que anticipa que la señal capturada corresponde al ciclo estacional y no a la desviación climática.

Tabla 6. Correlación de las variables climáticas nacionales con el número mensual de incendios (2000-2024).

Variable	Correlación
Temperatura nacional (t2m)	+0,894
Precipitación nacional (tp)	$-0,179$
Anomalía de temperatura	+0,058
Anomalía de precipitación	$-0,082$

El regresor de tendencia nacional alcanza un error absoluto medio de 123 incendios por mes y un R^2 de 0,891. No obstante, el análisis de importancia de variables muestra que el indicador `es_verano` concentra el 0,977 de la importancia total, frente a 0,012 de la temperatura nacional. El modelo, en rigor, aprendió la estacionalidad.




Figura 8. Incendios por año a nivel nacional (barras) frente a la anomalía de temperatura nacional de ERA5 (línea, reescalada). Gráfico del dashboard.

6.5 Modelo de riesgo comunal

Evaluado sobre las 578 combinaciones comuna-año de 2018 y 2019, el clasificador alcanza un accuracy global de 36,2 % sobre cuatro clases. El valor supera el 25 % esperable por azar, pero corresponde a una señal débil.

Tabla 7. Métricas por clase del clasificador de riesgo (conjunto de prueba 2018-2019).

Clase	Precisión	Recall	F1	Soporte
bajo	0,26	0,23	0,24	148
normal	0,48	0,61	0,54	161
alto	0,33	0,31	0,32	127
catastrófico	0,31	0,25	0,28	142
Promedio macro	0,34	0,35	0,35	578

El desempeño se concentra en la clase normal, que el modelo identifica razonablemente bien ($F1 = 0,54$), mientras que la clase bajo es la peor discriminada ($F1 = 0,24$) y se confunde con todas las demás. Pese al desempeño global modesto, las predicciones de mayor confianza resultan informativas: Lampa, con una probabilidad estimada de 0,75 para la clase catastrófica en 2019, efectivamente pertenecía a esa categoría.




Figura 9. Matriz de confusión del clasificador (izquierda) y las quince comunas con mayor probabilidad estimada de riesgo catastrófico para 2019 (derecha).




Figura 10. Importancia de variables del clasificador de riesgo (XGBoost).

El análisis de importancia arroja tres lecturas. La variable climática más influyente es la precipitación media (tp_medio, 0,061), por sobre la temperatura media (t2m_medio, 0,051). El índice de estrés hídrico construido en este proyecto se ubica en el décimo lugar (0,051), por encima de la mayoría de los indicadores regionales, lo que valida su aporte. Sin embargo, las variables de región ocupan ocho de los doce primeros puestos, encabezadas por Magallanes (0,073), Biobío (0,061) y Maule (0,060).

6.6 Entregable consolidado



Figura 11. Cabecera del dashboard HTML autocontenido con los indicadores principales del proyecto.

El dashboard reúne los indicadores de cobertura (60.530 eventos, 1.157.990 hectáreas, 312 comunas con al menos un evento y 16 regiones), los tres mapas embebidos mediante iframes, los gráficos analíticos y los resultados del modelo. Cada bloque incluye un texto explicativo orientado a lectores no técnicos.

7. Discusión

7.1 Contraste con la hipótesis

La hipótesis se confirma parcialmente, y el matiz depende de la escala de análisis. A nivel de evento individual la evidencia es sólida: los incendios catastróficos ocurrieron con una anomalía térmica 2,7 veces mayor y una precipitación 4,3 veces menor que el resto de los eventos. A nivel de comuna-año, en cambio, el clima por sí solo permite clasificar el riesgo apenas por encima del azar.

Esta aparente contradicción tiene una explicación coherente. La agregación anual diluye la señal: una comuna puede tener un año climáticamente normal en promedio y aun así concentrar un evento catastrófico ocurrido durante una ola de calor de tres días. La variable que discrimina opera en la escala del evento y de la semana, no en la del promedio anual.

7.2 Estacionalidad frente a anomalía

El resultado más instructivo del proyecto proviene de la rama nacional. La correlación de +0,894 entre temperatura e incendios podría interpretarse como una confirmación contundente de la hipótesis, pero la descomposición del modelo muestra que el 97,7 % de la capacidad predictiva proviene del indicador de estación. Dicho de otro modo: los incendios aumentan porque es verano, no porque ese verano haya sido anómalo. Distinguir ambas cosas exigía trabajar con anomalías, y esa distinción es precisamente la que justifica el índice construido.

7.3 El peso de la región y de la causa humana

Que las variables regionales dominen la importancia del clasificador no debe leerse como un defecto del modelo, sino como información. La región actúa como una variable proxy que condensa aquello que el modelo no observa directamente: tipo y densidad de vegetación, presencia de plantaciones forestales, densidad poblacional y extensión de la interfaz urbano-rural. Sumado a que

el 90,7 % de los eventos tiene causa humana identificada, el cuadro resultante es que el clima determina la disposición del territorio a arder, mientras que la actividad humana determina la ignición y la vegetación determina la magnitud.

7.4 Limitaciones

- La resolución espacial de ERA5 (0,25°, unos 27 km) es gruesa frente a la escala de un incendio y frente a la variabilidad topográfica de Chile, donde una misma celda puede abarcar valle y cordillera.
- La agregación a comuna-año diluye eventos extremos de corta duración, que son justamente los que concentran el 82 % de la superficie quemada.
- El modelo no incorpora variables de vegetación, viento ni humedad relativa, todas ellas determinantes conocidos del comportamiento del fuego.
- El cruce con clima real cubre 294 de los 480 meses de la serie nacional, lo que impide analizar tendencias de largo plazo con clima observado.
- El conjunto de prueba abarca solo dos años (2018-2019), ninguno de ellos comparable en magnitud a 2017, lo que limita la evaluación del modelo en condiciones extremas.

8. Conclusiones

7. Se integraron exitosamente tres fuentes de datos oficiales heterogéneas —eventos georreferenciados, grilla climática y serie histórica nacional— en un único modelo de datos a nivel de comuna y año, procesado con Apache Spark.
8. El índice de estrés hídrico propuesto resultó una medida válida y comparable entre comunas, y se ubicó entre las diez variables más influyentes del clasificador de riesgo.
9. La hipótesis se confirma a nivel de evento: los incendios catastróficos ocurren bajo anomalías térmicas casi tres veces mayores y con una cuarta parte de la precipitación que el resto.
10. La hipótesis no se sostiene como herramienta predictiva a nivel de comuna-año: un modelo alimentado solo con clima alcanza 36,2 % de accuracy frente al 25 % del azar.
11. La fuerte asociación entre temperatura e incendios a escala nacional se explica mayoritariamente por la estacionalidad del verano y no por anomalías climáticas.
12. El clima define el techo de lo que puede quemarse; la vegetación, la región y la actividad humana determinan cuánto se quema efectivamente. Un modelo puramente climático es útil para priorizar territorios, no para pronosticar incendios.

9. Trabajo futuro

- Incorporar variables de vegetación y uso de suelo, así como viento y humedad relativa, disponibles también en ERA5.
- Trabajar a escala mensual o de temporada en lugar de anual, para no diluir los episodios extremos de corta duración.
- Extender el conjunto de prueba a más temporadas e incluir 2017 como caso de validación extrema.

- Evaluar el uso de índices de peligro de incendio consolidados, como el Fire Weather Index, para contrastarlos con el índice propio.
- Publicar los mapas y el dashboard en un sitio estático para consulta pública.

10. Reproducibilidad

El repositorio se encuentra en github.com/Mtys24/MergeGeo. La ejecución requiere Google Colab con acceso a Google Drive y los siguientes archivos de entrada: el consolidado de incendios generado por los notebooks 01-02, los archivos NetCDF de ERA5 (`era5_t2m_chile_2000_2025.nc` y `era5_tp_chile_2000_2025.nc`) y la planilla del Archivo 6 de CONAF.

Los notebooks 01 y 02, así como la extracción de ERA5, ya se encuentran ejecutados y sus salidas versionadas. El orden de ejecución es 03 → 04 → 05 → 06 → 07 → 08 → 09. El notebook 09 debe ejecutarse en último lugar, y el archivo `dashboard.html` debe permanecer en la misma carpeta que los tres mapas HTML, ya que los incorpora mediante rutas relativas.

11. Equipo y roles

Tabla 8. Distribución de responsabilidades.

Integrante	Rol	GitHub
Jairo Arias Valenzuela	Extracción, limpieza y consolidación de los registros CONAF (1985-2024) y consumo estructurado de la API meteorológica Open-Meteo	@jairoarias208-beep
Fabian Valdés	Consultas y exploración de datos	@favc-5
Matías Manríquez	Visualización de datos: mapas geoespaciales interactivos en Folium y gráficos analíticos en Plotly	@Mtys24
Javiera González Mardones	Visualización de datos	@Zelaznog-J
José Salgado Escalona	Redacción del informe: estructura narrativa, redacción técnica y síntesis de hallazgos	@JoseRicardoSE

12. Fuentes

- CONAF. Estadísticas de incendios forestales, portal Datos para la Resiliencia (datospararesiliencia.cl). Temporadas 2010-2011 a 2019-2020.
- CONAF. Ocurrencia Nacional de Incendios Forestales según Mes, 1985-2024 (Archivo 6).
- Copernicus Climate Change Service (C3S). ERA5: reanálisis climático global, variables t2m y tp, resolución 0,25°, período 2000-2025. Climate Data Store.
- División político-administrativa comunal de Chile en formato GeoJSON, utilizada como base cartográfica de los mapas coropléticos.

Anexo A. Detalle de los notebooks

Tabla A1. Notebooks del pipeline, función y salida.

#	Notebook	Función	Salida
01	descargar_incendios_conaf	Descarga de 18 temporadas de CONAF vía API	incendios_conaf_raw.csv
02	preparar_incendios_para_era5	Limpieza y filtrado a Chile continental 2010-2019	incendios_conaf_2010_2020.xls
03	cruzar_incendios_era5	Cruce de cada evento con clima diario y anomalías mensuales	incendios_conaf_era5_2010_2020.csv / .parquet
04	agregacion_spark_comuna_anio	Agregación a comuna-año con PySpark, estrés hídrico y ranking	spark_comuna_anio/ (Parquet y CSV)
05	serie_nacional_mensual_mtys_era5	Cruce de la serie 1985-2024 con ERA5 nacional y regresor	incendios_nacional_mensual_era5.csv
06	mapa_georreferenciado_comuna	Mapas coropléticos de severidad y estrés hídrico	mapa_severidad_historica.html, mapa_estres_hidrico.html
07	mapa_puntos_importancia	Heatmap de densidad y capas de eventos destacados	mapa_puntos_importancia.html
08	modelo_riesgo_comuna_anio	Clasificación de riesgo en cuatro categorías	modelo_riesgo_comuna_anio.csv
09	dashboard	Consolidación de indicadores, mapas y resultados	dashboard.html

Anexo B. Parámetros y resultados del modelamiento

Tabla B1. Configuración y desempeño de los modelos.

Elemento	Modelo de riesgo comunal	Modelo de tendencia nacional
Algoritmo	XGBClassifier	XGBoost Regressor
Unidad de análisis	Comuna × año	Mes nacional
Registros	2.617 (train 2.039 / test 578)	294 meses cruzados con ERA5
Hiperparámetros	300 árboles, learning rate 0,05	Con salvaguardas anti-extrapolación
Partición	Temporal: 2010-2017 / 2018-2019	Serie completa 2000-2024
Desempeño	Accuracy 0,362 · F1 macro 0,35	MAE 123 incendios/mes · R² 0,891
Variable más influyente	region_Magallanes (0,073)	es_verano (0,977)

Tabla B2. Matriz de confusión del clasificador (filas: categoría real; columnas: predicha).

Real \ Predicho	bajo	normal	alto	catastrófico
bajo	34	39	37	38
normal	29	99	14	19
alto	36	26	40	25
catastrófico	33	44	29	36

Tabla B3. Severidad de los eventos individuales según los cortes aplicados en Spark.

Categoría	N° de eventos	Proporción
Menor	39.966	66,0 %
Moderado	15.983	26,4 %
Grave	3.994	6,6 %
Catastrófico	587	1,0 %